

基于离线交互历史的个性化提示词优化

冻结宿主模型，只优化每位用户的可读执行提示词

方法设计笔记 2026 年 8 月 29 日

1 结论

可以写一个与“离线策略学习”对应的提示词版本。它不训练本地策略模型，也不修改宿主模型。它从同一位用户的历史中生成、测试并改写一份提示词：

$$x \longrightarrow \text{FA}(p_u, x) \longrightarrow y. \quad (1)$$

但不能声称“此前没有人做过提示词版本”。已有工作至少覆盖了三块：

- DSO 从历史点击等反馈学习个性化提示词策略。策略根据用户和问题选择候选提示词，宿主模型保持冻结 [1]。
- AGP 自动改写用于推荐重排的用户画像生成提示词 [2]。
- GEPA 根据执行轨迹和文字反馈迭代提示词 [3]。

因此，新的研究点不能只是“用提示词做个性化”或“自动优化提示词”。更具体的问题是：

能否从一个用户的多会话智能体历史中，优化一份可读、可编辑的执行提示词，使它在后续任务中更符合该用户，同时不降低任务成功率？

下面给出一个可测试的方案。它还不是经过实验验证的算法。

2 问题设定

2.1 目标

给定用户历史 D_{hist} ，学习一份文本提示词 p_u 。宿主智能体保持冻结。提示词只控制三类执行行为：

- 何时使用当前会话的上下文；
- 何时直接回答、核实信息或先追问；
- 回答应直接、简短，还是分步展开。

提示词不替代任务推理。工具选择、代码执行、检索和最终回答仍由宿主智能体完成。

2.2 与离线策略版的区别

表 1: 两个版本优化的对象不同。

项目	离线策略版	提示词版
学习对象	动作策略 $\pi_{\theta}(a x)$	一份文本提示词 p_u
是否训练参数	训练本地策略模型	不训练宿主或本地策略模型
推理方式	先选离散动作，再编译成指令	宿主直接读取带条件的提示词
用户能否检查	只能间接检查动作分布	可以直接阅读、修改和删除
表达能力	受固定动作空间限制	可写条件规则，但可能变长或互相冲突

2.3 设计原则

- **宿主冻结**：所有候选提示词使用同一个宿主模型和同一套工具。
- **证据可查**：新增规则必须能指向训练侧的真实会话。
- **任务优先**：个性化提高时，任务成功率不能下降。
- **最终可读**：部署对象是一份普通文本，不是隐藏向量或软提示词。
- **测试隔离**：最终测试会话不参与提示词生成、改写或选择。

3 角色与符号

表 2: 系统中的角色。

角色	是否更新	职责
宿主智能体 FA	否	读取提示词，完成任务并生成最终回答
提示词改写器	否	根据失败案例和文字反馈提出新提示词
评审模型 Judge	否	比较回答是否符合训练侧用户证据，并给出简短修改建议
环境检查器	否	在可以自动验证的任务上判断是否真正完成任务
候选库	更新文本	保存提示词、来源、分数和每次改动

表 3: 主要符号。

符号	含义
D_{hist}	同一用户的完整历史
D_{opt}	生成初始提示词和改写反馈的数据
D_{select}	选择最终提示词的数据
D_{test}	只用于最终评测的数据
$p^{(t)}$	第 t 轮使用的提示词
$y(p, x)$	宿主在提示词 p 下对任务 x 的输出
$\mathcal{P}_t$	第 t 轮结束后的候选提示词库

4 提示词的结构

提示词沿用原策略版的三个执行维度，但把离散动作改成条件规则：

$$p = (p_{\text{context}}, p_{\text{information}}, p_{\text{response}}, p_{\text{avoid}}). \quad (2)$$

表 4: 一份提示词包含四段。

段落	内容
上下文使用	何时参考当前会话，何时只看本轮问题，以及哪些历史不能使用
信息获取	何时直接回答，何时先核实，何时必须追问缺失信息
回答方式	哪些任务需要直接结论、短答或分步说明
避免事项	用户反复拒绝的行为，以及不能覆盖的宿主安全规则

每条规则写成“条件 + 行为”。例如：

如果用户要求证明或推导，保留关键中间步骤；如果用户只要求结果，直接给出答案。

不要只写“用户喜欢详细回答”。前一种写法说明何时生效，也减少不同偏好之间的冲突。

5 数据边界

5.1 按会话和时间划分

先按时间排列完整会话，再按任务类别分层。默认可以使用 60%/20%/20% 的优化、选择和测试划分。比例必须在运行前固定。会话不可拆开：

$$D_{\text{opt}} \prec D_{\text{select}} \prec D_{\text{test}}. \quad (3)$$

表 5: 每部分数据的用途。

数据	允许的用途
D_{opt}	提取用户证据、生成初始提示词，并在内部轮换反馈任务和检查任务
D_{select}	搜索结束后比较候选库，并选择部署版本
D_{test}	最终一次评测；不能进入改写器或评审模型的上下文

优化任务优先使用 D_{opt} 中的真实问题。模拟问题只用于补足稀少类别。模拟问题必须过滤与 D_{select} 和 D_{test} 的近重复内容。

5.2 用户证据

从 D_{opt} 中提取反复出现、跨任务且仍然有效的偏好。每条证据保留会话编号和时间。改写器提出新规则时，必须列出支持它的证据编号。找不到证据的规则不进入提示词。

6 初始提示词

强推理模型先从 D_{opt} 生成结构化初稿：

$$p^{(0)} = \text{SummarizePreferences}(D_{\text{opt}}). \quad (4)$$

初稿只负责整理历史，不做搜索。它是必要基线。若后续优化不能稳定超过这份初稿，就没有证据说明自动改写有帮助。

7 离线提示词优化

7.1 生成执行结果和反馈

第 t 轮从 D_{opt} 选择一个按类别平衡的小批量 B_t 。对每个任务 x ，使用同一宿主、温度和工具设置运行当前提示词：

$$y_x^{(t)} = \text{FA}(p^{(t)}, x). \quad (5)$$

评审模型读取：

- 与任务相关的训练侧用户证据；
- 当前任务 x ；
- 宿主输出 $y_x^{(t)}$ ；
- 环境检查结果（若有）。

它返回三项内容：个性化判断、任务完成判断和一句具体修改建议。修改建议必须指出哪条提示词规则造成了问题，或缺少哪条有证据支持的规则。

7.2 改写候选

改写器根据当前提示词和失败反馈生成少量候选。每个候选只改一个段落，并给出文本差异。这样可以知道是哪项修改产生了效果：

$$\{p'_1, \dots, p'_K\} = \text{Revise}(p^{(t)}, B_t, \text{feedback}). \quad (6)$$

候选必须满足三个硬条件：

- 不加入训练历史中没有支持的用户偏好；
- 不删除宿主原有的安全和任务规则；
- 不超过预先设定的提示词长度。

7.3 选择规则

每轮从 D_{opt} 另取检查批次 V_t ，并保证 $V_t \cap B_t = \emptyset$ 。候选不能在产生其反馈的同一批任务上给自己打分。各轮轮换 B_t 和 V_t ，分别计算个性化效果和任务成功率：

$$U_{\text{pref}}(p; V_t) = \frac{1}{|V_t|} \sum_{x \in V_t} J_{\text{pref}}(D_{\text{opt}}, x, y(p, x)), \quad (7)$$

$$U_{\text{task}}(p; V_t) = \frac{1}{|V_t|} \sum_{x \in V_t} J_{\text{task}}(x, y(p, x)). \quad (8)$$

候选 p' 只有同时满足下面两项，才能替换当前提示词 p ：

$$U_{\text{pref}}(p'; V_t) > U_{\text{pref}}(p; V_t), \quad U_{\text{task}}(p'; V_t) \geq U_{\text{task}}(p; V_t). \quad (9)$$

还要按类别检查结果。不能用一个总体平均分掩盖某类任务的明显下降。若两个候选各自在不同类别更好，就都保留在候选库里，等更多选择数据后再决定。

7.4 停止

达到预先设定的运行预算，或连续若干轮没有候选通过选择规则时停止。搜索停止后，才首次用 D_{select} 比较候选库并选择 p^* 。整个过程不读取 D_{test} 。

8 完整流程

1. 按会话、时间和任务类别划分 $D_{\text{opt}}, D_{\text{select}}, D_{\text{test}}$ 。
2. 从 D_{opt} 提取带证据编号的用户偏好。
3. 生成结构化初始提示词 $p^{(0)}$ 。
4. 在 D_{opt} 任务上运行宿主并收集失败反馈。
5. 每轮只改一个提示词段落，生成候选。

- 6. 在 D_{opt} 内部轮换检查批次，比较候选。
- 7. 只接受个性化更好且任务成功率不下降的候选。
- 8. 搜索结束后，用 D_{select} 选择 p^* 。
- 9. 最后在 D_{test} 上评测一次。

9 推理

部署时不再调用改写器或评审模型。系统只加载宿主和最终提示词：

$$y = \text{FA}(p^*, x). \tag{10}$$

用户可以查看、修改或删除 p^* 。代价是每次请求都要携带这份文本，因此必须单独报告提示词长度和输入 token 成本。

10 评测

10.1 最少需要的对照

表 6: 建议的对照系统。

系统	回答的问题
无个性化提示词	宿主自身能做到什么？
直接提取的用户画像提示词	只整理历史是否已经足够？
本文的优化提示词	离线改写是否超过直接提取？
通用 GEPA 优化	改进是否来自已有提示词优化器？
DSO 提示词策略（有日志概率时）	动态选择提示词是否优于一份固定提示词？
原离线策略版	文本提示词与参数化动作策略哪一个更有效？

10.2 分开报告的指标

- 后续真实任务中的个性化符合度；
- 环境可验证的任务成功率；
- 各任务类别的结果和宏平均；
- 提示词长度、离线调用次数、推理 token 和延迟；
- 不同时间段上的偏好稳定性。

不要把这些指标压成一个总分。置信区间用于报告结果，不直接决定每次提示词改写。

11 已有工作与创新边界

表 7: 最接近的工作已经覆盖了哪些部分。

工作	已经做到	与本方案的差别
OPPU [4]	从每位用户的历史构造画像提示词，并与检索和参数训练比较	不迭代搜索一份执行提示词
DSO [1]	从日志反馈学习按用户和问题选择候选提示词的策略	优化的是提示词选择策略；主要实验是个性化电影描述，不是多步智能体任务
AGP [2]	自动优化用于推荐重排的用户画像生成提示词	优化对象是推荐场景中的画像生成，不是通用智能体执行规则
GEPA [3]	用执行轨迹和文字反馈进化提示词	默认优化任务程序，不专门建模单个用户的长期偏好
本方案	从一位用户的多会话历史优化一份可读执行提示词	同时检查个性化和真实任务成功率

因此，下面这些说法不成立：

- “首次用提示词做个性化”；
- “首次从离线反馈优化提示词”；
- “首次在冻结模型上学习提示词”。

可能尚未被直接覆盖的是更窄的组合：**单个用户、多会话智能体历史、一份可读执行提示词、任务成功约束、未来真实任务评测**。目前只能把它称为待验证的研究差异。正式投稿前仍需做更完整的文献检索。

12 建议先做的实验

1. 先使用现有用户历史，按会话和时间建立三段数据。
2. 固定宿主模型、工具、温度和最大输出长度。
3. 先跑“无提示词”和“直接提取提示词”。
4. 再实现上述单段改写和选择循环。
5. 用相同预算运行 GEPA，避免把已有优化器的能力算成新方法。
6. 与原来的 18 动作策略版做同题比较。
7. 只有在真实测试任务上同时改善个性化和任务成功，才继续做部署后的在线更新。

参考文献

- [1] Haruka Kiyohara et al. Prompt Optimization with Logged Bandit Data. [arXiv:2504.02646](#), 2025.
- [2] Chen Wang et al. Automating Personalization: Prompt Optimization for Recommendation Reranking. [arXiv:2504.03965](#), 2025.
- [3] Lakshya A. Agrawal et al. GEPA: Reflective Prompt Evolution Can Outperform Reinforcement Learning. [arXiv:2507.19457](#), 2025.
- [4] Zhaoxuan Tan et al. Democratizing Large Language Models via Personalized Parameter-Efficient Fine-Tuning. [EMNLP](#), 2024.