

基于提示词动作的离线到在线个性化策略学习

冻结 FA 和 Judge，只训练轻量策略

中文算法设计笔记 2026 年 8 月 29 日

1 结论

可以把原方案改成提示词版本，但不能把策略改成最终回答模型。原方案的主链必须保留：

$$x \longrightarrow a \sim \pi_\theta(\cdot | x) \longrightarrow \text{FA. Execute}(a, x) \longrightarrow y_a. \quad (1)$$

策略仍然只决定如何执行。冻结的 FA 读取任务 x 和执行指令 a ，再生成最终回答 y_a 。

本版本只改两处：

- a 不再是固定的三因子标签，而是一条自然语言执行指令；
- $\mathcal{A}$ 不再是手写的 18 个动作，而是从真实用户纠正中得到、经执行验证的指令库。

因此不再需要 Compiler。除此之外， $D_{\text{hist}}, D_{\text{train}}, D_{\text{holdout}}, \mathcal{X}_{\text{holdout}}, \tilde{\mathcal{X}}, C, c, P_u, y_a, r_a, A_a, \pi_\theta, \pi_{\text{base}}$ 、FA 和 Judge 都保留原义。

提示词优化和提示词选择已有研究，不能声称“此前没有人做过提示词版本”。较窄、仍需实验验证的差异是：一个用户、冻结的黑盒 FA、由真实纠正形成的可查指令库、轻量策略选择指令，以及同一套离线到在线 GRPO 更新。

2 哪些部分不变

2.1 角色

表 1: 模型角色沿用原 PDF。

角色	是否训练	职责
Frozen Agent (FA)	否	可选地整理 P_u ，构造训练问题，执行指令 a ，生成最终回答 y_a
Policy π_θ	是	输入当前任务 x ，在可用指令中选择 a
Base π_{base}	否	与 π_θ 使用同一主干；关闭用户 LoRA，作为初始化和评测对照
Judge	否	根据训练侧真实历史、任务结果和可选的 P_u 给 y_a 标量分 r_a
提示词动作库 $\mathcal{A}$	数据，不是模型	保存已经过验证的自然语言执行指令及其证据

模型参数中只有 θ 更新。FA、Judge、 P_u 和 π_{base} 始终冻结。 $\mathcal{A}$ 是数据表；在线收到新纠正后可以增加记录，但这不等于训练另一个模型。

表 2: 原符号在本版本中的含义。

符号	含义
D_{hist}	同一用户按时间排列的完整历史
$D_{\text{train}}, D_{\text{holdout}}$	按完整会话和时间切开的训练历史与保留历史
$\mathcal{X}_{\text{holdout}}$	只用于最终评测的真实用户问题
$\tilde{\mathcal{X}}$	只由训练侧信息构造的训练任务
C, c	预先固定的任务类别集合及单个类别
P_u	只从 D_{train} 提取并冻结的可选用户偏好摘要
a	交给 FA 的自然语言执行指令，不是最终回答
$\mathcal{A}$	当前用户的已验证执行指令集合，不再固定为 18 个
y_a	FA 在任务 x 下执行指令 a 后的回答
r_a	Judge 对 y_a 的标量分
$A_a = r_a - \bar{r}$	同一任务内的组相对优势
$\pi_{\theta}(a x)$	可训练的提示词动作策略
π_{base}	关闭 LoRA 后的冻结基础策略

2.2 符号逐项对应

3 为什么选择指令库

提示词动作有三种直接做法：

- **自由生成**：策略每次写一条新指令。表达力强，但容易加入用户从未说过的偏好，也很难审计。
- **适配器库**：策略选择一个参数适配器。它不再是提示词版本，也不适合只能通过 API 调用的冻结 FA。
- **已验证指令库**：每条指令来自真实纠正，保存来源，并先经过 FA 和 Judge 验证。策略只在这些指令中选择。

本文采用第三种。它最接近原来的离散动作策略，也保留了黑盒 FA 的边界。它只是一个候选方法，不表示提示词一定优于参数适配器。

4 提示词动作空间

4.1 一条动作是什么

每条 $a \in \mathcal{A}$ 是可以直接放进 FA system message 的短指令。例如，当前 OOC SO 诊断样本中的纠正 是：

别整这些花里胡哨的格式啊，你就老老实实说人话重写一遍呗。

可以从中提出候选指令：

使用普通中文短句；不要加粗、编号或小标题。

后一句只有在回放原任务后确实改善回答，才进入 $\mathcal{A}$ 。指令必须描述执行方式，不能泄露任务答案，也不能替代 FA 完成任务。

每条库记录至少包含：

字段	内容
instruction	交给 FA 的指令文本，即动作 a
scope	global 或适用的任务类别 c
evidence_ids	支持这条指令的 D_{train} 会话和轮次
validation_ids	已完成执行验证的训练任务
status	只有 validated 才能进入策略候选集

指令库总是包含空动作 $a_{\emptyset}$ 。它不添加个性化指令，用来判断个性化是否真的有帮助。

4.2 从真实纠正建立动作

只使用 D_{train} ：

1. 找到用户明确要求修改，且修改后回答被接受的轮次。
2. 冻结 FA 把用户原话整理成一条短执行指令。它只能删去题目内容和重复文字，不能补充新偏好。
3. 在纠正前的任务 x 上运行空动作和候选动作，得到两个 FA 回答。
4. Judge 读取同一段训练侧证据并比较两个回答。有确定性任务检查器时，Judge 也读取任务是否成功。
5. 只有候选动作改善偏好且不破坏任务完成时，才标为 validated。

空反馈、未闭合思考块导致的空文本、少于一个完整要求的 hint，以及纠正后仍不满意的记录全部丢弃。当前数据里出现过只剩“和”的损坏 hint；它不能成为动作。

4.3 当前任务的候选集

每条指令在入库时已有适用范围。对类别为 $c(x)$ 的任务，

$$\mathcal{A}_x = \{a_{\emptyset}\} \cup \{a \in \mathcal{A} : \text{scope}(a) = \text{global 或 } c(x) \in \text{scope}(a)\}. \quad (2)$$

首个实验直接枚举 $\mathcal{A}_x$ 。只有库变得很大后，才加入固定的检索上限。检索规则必须在评测前锁定，不能读取 D_{holdout} 。

5 策略模型

5.1 参数

π_θ 使用当前 OOCSSO 已配置的 Qwen/Qwen3-4B-Thinking-2507。每位用户有一个 LoRA:

$$r = 16, \quad \alpha = 32, \quad \text{target} = \{\text{q_proj}, \text{k_proj}, \text{v_proj}, \text{o_proj}\}.$$

当前 `preview_pi0_student.pt` 有 288 个 LoRA 张量, 共 11,796,480 个参数。该文件只能说明当前代码已经能保存适配器, 不能证明本文算法已实现。

5.2 输入

策略输入仍然只有 x 。序列化格式固定为:

[TASK_STATE]

当前 system message、用户任务、已经发生的工具返回和对话状态

[/TASK_STATE]

[EXECUTION_INSTRUCTION]

评测第一次回答时, x 不包含当前任务尚未发生的用户纠正。用户偏好存于该用户的 LoRA 和已验证动作库中。 P_u 不拼进策略输入。

5.3 输出和候选打分

输出是动作文本 $a = (t_1, \dots, t_{L_a})$, 不是回答。对每个 $a \in \mathcal{A}_x$, 用 teacher forcing 计算长度归一化分数:

$$s_\theta(a, x) = \frac{1}{L_a} \sum_{j=1}^{L_a} \log p_\theta(t_j \mid \text{Serialize}(x), t_{<j}). \quad (3)$$

空动作使用固定 token `<NO_PERSONAL_INSTRUCTION>` 参与打分, 传给 FA 时再还原为空字符串。候选上的策略分布为

$$\pi_\theta(a \mid x) = \frac{\exp(s_\theta(a, x)/T)}{\sum_{a' \in \mathcal{A}_x} \exp(s_\theta(a', x)/T)}. \quad (4)$$

π_{base} 使用同一公式和同一动作库, 但关闭 LoRA。这样两条评测链只差训练过的策略参数。

6 离线算法

6.1 数据切分

先按完整会话和时间把 D_{hist} 切成 D_{train} 和 D_{holdout} 。一个会话不能拆到两边。任务类别 C 和比例在运行前固定。只有 D_{train} 可以用于:

- 建立 $\mathcal{A}$;

- 提取可选的 P_u ;
- 构造 $\tilde{\mathcal{X}}$;
- 给 Judge 提供偏好证据;
- 训练 π_θ 。

D_{holdout} 和 $\mathcal{X}_{\text{holdout}}$ 不得进入以上任何一步。

6.2 执行与打分

对每个 $x \in \tilde{\mathcal{X}}$, 枚举或从 $\mathcal{A}_x$ 采样 K 条指令。每条指令都通过同一个冻结 FA:

$$y_a = \text{FA.Execute}(a, x). \quad (5)$$

这里没有 Compiler。动作文本 a 直接进入 FA。

Judge 读取训练侧真实证据、任务 x 、回答 y_a , 以及可选的冻结摘要 P_u :

$$r_a = \text{Judge}(D_{\text{train}}, x, y_a; P_u). \quad (6)$$

对工具任务, 确定性检查器的成功或失败也放进 Judge 输入。Judge 仍只输出一个固定范围的标量 r_a 。同一 x 下的所有回答必须使用同一个 Judge 提示和同一套 FA 参数。

6.3 组相对优势

$$\bar{r} = \frac{1}{K} \sum_{a \in \mathcal{A}_x^{(K)}} r_a, \quad A_a = r_a - \bar{r}. \quad (7)$$

若所有动作得分相同, 该组不产生梯度。不要为制造优势而改 Judge 分数。

6.4 GRPO 更新

收集动作时保存 $\pi_{\theta_{\text{old}}}(a | x)$ 。更新时计算

$$\rho_a(\theta) = \frac{\pi_\theta(a | x)}{\pi_{\theta_{\text{old}}}(a | x)}. \quad (8)$$

使用原方案的 clipped GRPO:

$$\mathcal{L}_{\text{GRPO}}(\theta) = -\mathbb{E}_x \left[\frac{1}{K} \sum_a \min(\rho_a A_a, \text{clip}(\rho_a, 1 - \epsilon, 1 + \epsilon) A_a) \right] - \beta H(\pi_\theta(\cdot | x)). \quad (9)$$

优化器只更新 LoRA 参数 θ 。FA 和 Judge 的 token 概率不进入损失。

6.5 离线工作流

1. 切分 D_{hist} ，冻结 D_{holdout} 和 $\mathcal{X}_{\text{holdout}}$ 。
2. 从 D_{train} 的真实纠正建立并验证 $\mathcal{A}$ 。
3. 可选地从 D_{train} 提取一次 P_u ，随后冻结。
4. 从训练侧任务构造 $\tilde{\mathcal{X}}$ ，并过滤与 holdout 的近重复。
5. 对每个 x 形成 $\mathcal{A}_x$ ，通过 FA 得到 y_a 。
6. Judge 给出 r_a ，计算 A_a 。
7. 用式 (9) 更新 π_θ ，得到离线策略 π_0 。

7 在线算法

部署从离线策略 π_0 和同一动作库开始。每次任务仍按式 (1) 执行。在线数据分两类处理：

- 用户满意或任务成功：保存该次 (x, a, y_a, r_a) ，用于后续组相对更新；
- 用户明确纠正：从用户原话提出一个新动作候选，但不能直接加入 $\mathcal{A}$ 。

新候选先经过三项检查：

1. 它能指向当前在线纠正，且没有加入用户未表达的要求；
2. 在当前任务上重新运行 FA 后，Judge 分数提高且任务仍成功；
3. 在一小批已通过的训练侧回放任务上，不造成明显退化。

通过后，候选成为 $\mathcal{A}$ 的新记录。然后在包含新动作、当前动作、空动作和若干旧动作的组内重新执行、打分，并继续使用式 (9)。在线阶段没有第二套训练目标。 D_{holdout} 和 $\mathcal{X}_{\text{holdout}}$ 始终不可见。

8 推理

对新任务 x ：

1. 按式 (2) 得到 $\mathcal{A}_x$ ；
2. 按式 (4) 计算动作分布；
3. 评测时取 $a^* = \arg \max_a \pi_\theta(a | x)$ ，交互时也可采样；
4. 运行 $y_{a^*} = \text{FA.Execute}(a^*, x)$ ；
5. 返回 y_{a^*} 。

默认不把 P_u 再拼进 FA。这样可把效果归因于动作策略，而不是额外的完整用户画像提示。 P_u 仍可作为单独基线。

9 与 OOC SO 数据的对应

表 3: OOC SO data 目录中各文件的实际用途。

文件	对应位置	当前边界
preview_pipeline.json	D_{hist} 流程样本	只有 4 个偏好任务、2 条离线线程和 3 条在线记录，只能做单元测试
dump_samples.json	纠正样本	只有 3 条离线和 2 条在线诊断会话；包含真实失败模式，但不是完整历史
tasks_train.jsonl	$\tilde{\mathcal{X}}$ 与在线训练流	120 个工具任务；当前代码用 0–79 做离线，80–119 做在线
tasks_dev.jsonl	开发检查	30 个任务，只能用于调试和选参
tasks_eval.jsonl	任务成功 holdout	30 个工具任务，可检查任务完成，不能替代真实个性化 $\mathcal{X}_{\text{holdout}}$
preview_pi0_student.pt	π_0 文件格式	现有 LoRA 快照，不是本文提示词动作策略的训练结果

当前七类工具任务为

$$C = \{\text{single_tool}, \text{two_step_chain}, \text{chain3}, \text{cross_rate}, \text{cross_rate3}, \text{sum_two}, \text{error_correction}\}.$$

这里有一个重要缺口：当前目录没有可直接作为正式 D_{train} , D_{holdout} , $\mathcal{X}_{\text{holdout}}$ 的完整真实用户历史。现有 JSON 只能验证代码路径。正式实验前，必须保存完整会话，先按时间切分，再从训练侧提取动作。不能把 30 个合成 tasks_eval.jsonl 任务写成“真实用户 holdout”。

10 当前代码与本文算法的关系

现有 oocso/pref/run_pref.py 让 Qwen3-4B 直接生成回答，再用 GRPO/OPD 更新回答 token。本文不是那条代码路径。本文的 π_θ 只给候选执行指令打分，最终回答由 FA 生成。

若开始实现，应放在新的 pref_prompt_action_grpo/ 目录，复用以下通用部分：

- config.py 的模型名和 LoRA 参数；
- env/ 的工具执行与成功检查；
- pref/pref_prm.py 的冻结 Judge 接口；
- models.py 的 teacher-forcing log-prob 计算。

不要修改现有直接回答实验，避免两种架构混在一起。

11 评测

11.1 对照

表 4: 最少需要的对照。

系统	回答的问题
空动作 + FA	不做个性化时, FA 本身表现如何?
$\pi_{\text{base}} + \mathcal{A} + \text{FA}$	未训练的基础模型能否靠语言先验选对指令?
$\pi_{\theta} + \mathcal{A} + \text{FA}$	用户 LoRA 是否学会按任务选择指令?
P_u 直接提示 + FA	每次携带完整用户摘要是否已经足够?
原 18 动作策略 + Compiler + FA	数据派生指令是否优于固定手写动作?
自由生成提示词 + FA	指令库的可审计约束是否值得其表达能力损失?

11.2 报告

对真实 $\mathcal{X}_{\text{holdout}}$, 比较训练策略与基础策略在同一 FA 下的回答。按类别报告:

$$\text{Acc}_c = \frac{1}{N_c} \sum_{x \in \mathcal{X}_{\text{holdout}}^{(c)}} \mathbf{1}[y_{\theta} \succ y_{\text{base}}], \quad (10)$$

$$\text{Acc}_{\text{macro}} = \frac{1}{|C|} \sum_c \text{Acc}_c, \quad (11)$$

$$\text{Acc}_{\text{micro}} = \frac{1}{N} \sum_c N_c \text{Acc}_c. \quad (12)$$

另外单独报告任务成功率、第一次回答符合偏好的比例、动作库大小、动作长度、FA 调用次数和在线新增动作数。不要把个性化和任务成功压成一个分数。

12 已有工作与创新边界

以下方向已有直接工作:

- DSO 从日志反馈学习按上下文选择提示词;
- AGP 自动改写个性化推荐中的画像提示词;
- GEPA 根据执行轨迹和文字反馈迭代提示词;
- OPPI 为每位用户训练独立的参数高效适配器。

因此,“提示词个性化”、“冻结模型后优化提示词”和“根据反馈改写提示词”都不是新的。本文可能不同的是完整组合,而不是任何一个单独部件。正式写成论文贡献前,还需要更完整的文献检索和直接对照实验。

参考文献

- [1] Haruka Kiyohara et al. Prompt Optimization with Logged Bandit Data. [arXiv:2504.02646](#), 2025.
- [2] Chen Wang et al. Automating Personalization: Prompt Optimization for Recommendation Reranking. [arXiv:2504.03965](#), 2025.
- [3] Lakshya A. Agrawal et al. GEPA: Reflective Prompt Evolution Can Outperform Reinforcement Learning. [arXiv:2507.19457](#), 2025.
- [4] Zhaoxuan Tan et al. Democratizing Large Language Models via Personalized Parameter-Efficient Fine-Tuning. [EMNLP](#), 2024.

13 最小可行实验

当前数据只够做流程验证：

1. 从现有三条有效纠正中提取候选动作，并确认损坏 hint 被拒绝。
2. 在 80 个离线工具任务上比较空动作和已验证动作。
3. 训练一个新的提示词动作 LoRA，不复用当前直接回答检查点作为结果。
4. 用 30 个 dev 任务检查任务成功是否下降。
5. 暂不对 30 个 eval 任务报告正式个性化结论。

正式实验还需要一位真实用户的完整历史，以及按时间保留的未来问题。没有这两项时，可以证明代码能运行，但不能证明离线个性化或在线适应有效。