

基于历史执行证据选择的离线到在线个性化策略学习

完全保留原符号和冻结 FA 设定，只替换 18 动作与 Compiler

中文算法设计笔记 2026 年 8 月 29 日

1 最终选择

本文以 /fsx/xzhichao/workspace/offlinetraining/Offline_training_algorithm(2).pdf 为唯一符号来源。主链保持为

$$x \longrightarrow a \sim \pi_{\theta}(\cdot | x) \longrightarrow \text{FA.Execute}(a, x) \longrightarrow y_a. \quad (1)$$

策略不生成最终回答。冻结的 FA 读取当前任务 x 和动作 a ，再生成 y_a 。

原方案真正有问题的是

$$a = (m, \tau, s), \quad |\mathcal{A}| = 18,$$

以及把标签翻译成手写指令的 Compiler。OOCSSO 数据并不包含这 18 个标签。它包含完整状态、失败回答、用户纠正、改后回答和用户是否接受。因此，本版本把 a 的**内部表示**替换为从 $\mathcal{D}_{\text{train}}$ 选择出的历史记录索引。符号 $a, \mathcal{A}$ 不改。

新动作： a 是一个有序的历史记录索引列表。每个索引都指向 $\mathcal{D}_{\text{train}}$ 中一段已被用户接受的真实执行记录。FA 直接读取这些原始消息，然后完成当前任务。没有标签到提示词的翻译，也没有模型生成的偏好规则。

这比自由生成提示词更适合当前数据：每个动作都能追溯到文件和 JSON 路径，在线收到新纠正后也可以直接加入新记录。

2 不可改变的合同

2.1 符号

本文不引入 D_{opt} 、 D_{select} 、提示词集合 $\mathcal{P}$ 或另一套奖励符号。所有后续公式继续使用上表。

2.2 角色

模型参数中只有 θ 更新。FA、Judge、 P_u 和 π_{base} 全程冻结。训练奖励必须来自 y_a 的执行结果，不能直接给索引动作打规则分。

3 OOCSSO 数据合同

3.1 实际文件

dump_samples.json、preview_offline.json 和 preview_online_partial.json 与上述流程有重复，只用于诊断，不能重复计数。preview_pi0_student.pt 与 preview_pi0_ta.pt 是旧的 4B 直接

表 1: 原 PDF 的核心符号, 以及历史选择动作的内部符号。

符号	含义
$\mathcal{D}_{\text{hist}}$	完整历史
$\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{holdout}}$	分层后的训练历史与评测历史
$\mathcal{X}_{\text{holdout}}$	holdout 真实用户问题
$\tilde{\mathcal{X}}$	训练问题
C, c	任务类别集合与单个类别
x	策略选择动作时已经可见的当前任务状态; 不含本轮尚未发生的反馈
$i, \mathcal{D}_{\text{train}}[i]$	一条历史执行记录的稳定编号, 以及该编号指向的记录内容
P_u	可选的结构化偏好摘要, 只辅助 Judge
a	执行动作; 本文只替换它的内部表示
$\mathcal{A}$	动作集合
y_a	FA 在动作 a 下的回答
r_a	Judge 对 y_a 的标量分
$A_a = r_a - \bar{r}$	组内优势
$\pi_{\theta}(a x)$	可训练策略
π_{base}	初始化 π_{θ} 的冻结基础策略

回答 LoRA, 不是本文选择策略的检查点, 不能继续训练后当作本文结果。

3.2 类别

现有工具任务给出七个固定类别:

$$C = \{\text{single_tool}, \text{two_step_chain}, \text{chain3}, \text{cross_rate}, \\ \text{cross_rate3}, \text{sum_two}, \text{error_correction}\}.$$

每个 JSONL 任务已经含 c 、允许工具、正确答案、容差和最大步数。不重新让模型猜类别。

3.3 一条可选历史记录

从 $\mathcal{D}_{\text{train}}$ 中只保留最终被用户接受的记录。每条记录按固定规则保存:

- 源文件与 JSON Pointer;
- 用户角色与历史任务文本;
- 源记录已有的任务类别 c (若存在; preview 数学记录没有该字段);
- 纠正前状态;

表 2: 角色边界与原 PDF 相同。

角色	是否更新	职责
Frozen Agent (FA)	否	可选地提取 P_u , 执行 a , 完成任务并生成 y_a
Policy π_θ	是	输入 x , 输出 $a \in \mathcal{A}$
Base π_{base}	否	与 π_θ 使用同一主干, 关闭用户 LoRA
Judge	否	读取训练侧真实历史、 x 、 y_a 和可选的 P_u , 输出 r_a

表 3: 本算法实际读取的 OOC SO 文件。

文件	用途	已核对规模
preview_pipeline.json	student 的离线历史与在线流	离线 8 条已接受记录, 其中 2 条先被纠正; 在线 3 条, 三条都先被纠正
preview_pipeline_ta.json	TA 的离线历史与在线流	离线 2 条、在线 2 条, 全部首次即被接受
tasks_train.jsonl	$\tilde{\mathcal{X}}$ 与在线任务流	120 个工具任务; 当前代码约定 0–79 离线、80–119 在线
tasks_dev.jsonl	开发检查	30 个任务
tasks_eval.jsonl	任务成功 holdout	30 个任务; 不能冒充真实个性化 $\mathcal{X}_{\text{holdout}}$

- 失败回答与用户纠正 (若存在);
- 最终被接受的回答;
- 用户接受信号, 以及源记录已有的任务成功结果 (若存在)。

Qwen Thinking 输出只保留最后一个 `</think>` 后的用户可见部分。没有闭合 `</think>` 的输出视为空回答, 不进入动作。历史文本不做总结, 不由 LLM 改写。

3.4 当前数据边界

表 4: 当前可运行范围。

用户	离线	在线	结论
student	8 条, 2 条含纠正	3 条, 3 条含纠正	可做小规模流程验证
TA	2 条, 均为正例	2 条, 均为正例	可验证读取, 不能稳定比较学习
teacher	无训练轨迹	无训练轨迹	目前不能训练

`pref_config_snapshot.json` 与当前 `pref/detectors.py` 对 TA 和 teacher 的偏好方向不一致，因此不能作为标签来源。本算法以实际轨迹、当前 detector 和任务检查器为准。

当前目录也没有正式的真实用户 $\mathcal{D}_{\text{holdout}}$, $\mathcal{X}_{\text{holdout}}$ 。因此现有数据可以证明流程是否运行，但不能支持最终个性化结论。

4 新的动作 a

4.1 定义

设 $\mathcal{D}_{\text{train}}$ 中可用记录有稳定索引。动作写成

$$a = (i_1, i_2, \dots, i_k, \text{STOP}), \quad (2)$$

其中每个 i_j 都是一个源记录索引。顺序表示 FA 看到这些历史的顺序。若第一项就是 `STOP`，FA 不读取任何个性化历史。

$\mathcal{A}$ 是在证据 token 预算内的所有合法有序索引列表。首个实现固定

$$B_{\text{ctx}} = 4096$$

作为历史证据预算；当前任务 x 、工具描述和 FA 输出预算另计。某条记录加入后超过 B_{ctx} ，该记录在当前选择步不可用。

4.2 FA 如何执行

索引只做原样查表：

1. 根据 $i_1, \dots, i_k$ 读取源 JSON 中的消息；
2. 按源顺序放入 FA 的历史消息区；
3. 在末尾放入当前任务 x ；
4. 由同一个冻结 FA 完成任务，得到 y_a 。

这里没有 Compiler。系统不会把索引翻译成“简短回答”“多问一句”之类的新文本。动作指向的就是原始历史消息。

4.3 为什么不是其他方案

- **固定 18 动作：**数据没有这些标签，表达能力也被手写轴限制。
- **自由生成提示词：**会加入用户从未表达的偏好，且难以追溯。
- **直接训练回答模型：**改变了式 (1)，最终回答不再来自冻结 FA。
- **给 FA 加 adapter：**远程黑盒 FA 无法加载本地 adapter，也会改变“FA 冻结”的边界。

历史选择动作只决定 FA 在执行前看到哪些真实证据，最符合现有数据和冻结宿主条件。

5 小策略模型

5.1 模型和参数

π_θ 使用本机已有的 Qwen/Qwen3-0.6B, 不是当前 4B 直接回答模型。已核对的主干配置为:

28 层, $d = 1024$, 16 个 query heads, 8 个 KV heads, 40960 token 上限.

主干冻结。每位用户单独加载一个 LoRA:

$$r = 16, \quad \alpha = 32, \quad \text{dropout} = 0,$$

目标层为每层的 $\mathbf{q_proj}, \mathbf{k_proj}, \mathbf{v_proj}, \mathbf{o_proj}$ 。根据实际权重形状, LoRA 可训练参数数目为

$$28 \times 16[(1024 + 2048) + (1024 + 1024) + (1024 + 1024) + (2048 + 1024)] = 4,587,520.$$

student、TA 和 teacher 不共享 LoRA。

5.2 输入

模型不接收 P_u , 也不接收用户 ID。加载哪个 LoRA 已经确定当前用户。

这里, x 是策略作出选择时已经可见的完整任务状态, 包括当前用户请求、此前对话与工具结果、当前可用工具和类别 c 。它不是某个 token, 也不包含当前回答之后才会出现的用户反馈。策略把 x 序列化为:

[CURRENT] 当前状态、任务文本、允许工具和类别 c [/CURRENT]

每个 i 是 $\mathcal{D}_{\text{train}}$ 中一条历史执行记录的稳定编号, $\mathcal{D}_{\text{train}}[i]$ 才是该编号指向的记录内容。策略把 $\mathcal{D}_{\text{train}}[i]$ 序列化为:

[HISTORY] 源路径、用户角色、历史任务、失败回答与纠正 (若有)、被接受回答、已有结果
[/HISTORY]

评测首次回答时, 当前任务输入不能出现尚未发生的用户纠正。历史候选只能来自 $\mathcal{D}_{\text{train}}$ 或已经完成的更早在线交互。

5.3 输出

策略输出的是式 (2) 的源索引列表, 不输出自然语言, 不输出工具调用, 也不输出最终回答。

记 $\text{Serialize}_{\text{task}}(x)$ 为上面的当前任务文本, $\text{Serialize}_{\text{hist}}(\mathcal{D}_{\text{train}}[i])$ 为上面的历史记录文本。LastHidden 取 Qwen 最后一层中最后一个非 padding token 的 1024 维隐藏向量。两个输入分别编码为

$$\mathbf{e}_\theta^{\text{task}}(x) = \text{normalize}(\text{LastHidden}[\text{Qwen}_\theta(\text{Serialize}_{\text{task}}(x))]), \quad (3)$$

$$\mathbf{e}_\theta^{\text{hist}}(i) = \text{normalize}(\text{LastHidden}[\text{Qwen}_\theta(\text{Serialize}_{\text{hist}}(\mathcal{D}_{\text{train}}[i]))]). \quad (4)$$

其中 $\text{normalize}(\mathbf{z}) = \mathbf{z}/\|\mathbf{z}\|_2$ 。历史记录 i 对当前任务 x 的分数是两者的余弦相似度：

$$s_\theta(x, i) = \left(\mathbf{e}_\theta^{\text{task}}(x) \right)^\top \mathbf{e}_\theta^{\text{hist}}(i). \quad (5)$$

$\mathbf{e}_\theta^{\text{task}}$ 和 $\mathbf{e}_\theta^{\text{hist}}$ 只是任务与历史记录的表示，**不是** Transformer attention 内部的 query、key 或 value。上文的 `q_proj`, `k_proj`, `v_proj` 仍按 Qwen 的正常前向过程产生隐藏状态；式 (5) 不直接读取它们。

STOP 也用固定文本编码成一个候选。没有新分类头。式 (6) 中的 T 控制 cosine score 的温度；首个实现使用 $T = 0.05$ 。

5.4 动作概率

令 $V_j(x)$ 表示第 j 步尚未选择、且仍能放进 B_{ctx} 的索引集合。第 j 步，

$$p_\theta(i_j | x, i_{<j}) = \frac{\exp(s_\theta(x, i_j)/T)}{\exp(s_\theta(x, \text{STOP})/T) + \sum_{\ell \in V_j(x)} \exp(s_\theta(x, \ell)/T)}. \quad (6)$$

选中 STOP 后结束。完整动作概率仍使用原符号：

$$\pi_\theta(a | x) = \left[\prod_{j=1}^k p_\theta(i_j | x, i_{<j}) \right] p_\theta(\text{STOP} | x, i_{\leq k}). \quad (7)$$

π_{base} 是同一个 Qwen3-0.6B，关闭 LoRA，并使用相同候选记录、温度和 token 预算。这样 base 与训练策略只差 θ 。

6 离线阶段

6.1 数据准备

1. 先按完整 session 和时间切分 $\mathcal{D}_{\text{hist}}$ 为 $\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{holdout}}$ ；切分后不得移动记录。
2. 只从 $\mathcal{D}_{\text{train}}$ 建立可选历史记录。
3. 可选地由 FA 从 $\mathcal{D}_{\text{train}}$ 提取一次 P_u ，随后冻结； P_u 只给 Judge。
4. 当前 OOCSSO 首次实现直接把 `tasks_train.jsonl` 的 0-79 号任务作为 $\tilde{\mathcal{X}}$ ，不再让 FA 另造题。
5. $\mathcal{D}_{\text{holdout}}, \mathcal{X}_{\text{holdout}}$ 不参与候选建立、Judge 造分、选参或训练。

6.2 执行与打分

对每个 $x \in \tilde{\mathcal{X}}$ ，从 $\pi_{\theta_{\text{old}}}$ 采样 $K = 8$ 个不同动作。每个动作都交给同一个冻结 FA：

$$y_a = \text{FA}. \text{Execute}(a, x). \quad (8)$$

Judge 输入保持原 PDF 的定义：

$$r_a = \text{Judge}(\mathcal{H}_{\text{train}}, x, y_a; P_u^{\text{opt}}), \quad (9)$$

其中 $\mathcal{H}_{\text{train}}$ 只来自 $\mathcal{D}_{\text{train}}$ 。对工具任务，Judge 同时读取 `tasks_train.jsonl` 中的正确答案、容差和任务检查结果。任务失败不能靠写作风格获得高分。同一个 x 下所有 y_a 使用相同 Judge 提示和温度。

6.3 组内优势

完全沿用原式：

$$\bar{r} = \frac{1}{K} \sum_a r_a, \quad A_a = r_a - \bar{r}. \quad (10)$$

若八个动作得分相同，该组不产生策略梯度。

6.4 GRPO

收集动作时保存 $\pi_{\theta_{\text{old}}}(a | x)$ 。更新时

$$\rho_a(\theta) = \frac{\pi_{\theta}(a | x)}{\pi_{\theta_{\text{old}}}(a | x)}. \quad (11)$$

使用 clipped GRPO：

$$\mathcal{L}_{\text{GRPO}}(\theta) = -\mathbb{E}_{x \sim \tilde{\mathcal{X}}} \left[\frac{1}{K} \sum_a \min(\rho_a A_a, \text{clip}(\rho_a, 1 - \epsilon, 1 + \epsilon) A_a) \right]. \quad (12)$$

只更新 4,587,520 个 LoRA 参数。FA 和 Judge 的 token 概率不进入损失。离线结束得到 π_0 。

7 在线阶段

在线阶段从同一 π_0 、同一动作格式和同一 Judge 开始。当前 OOCSSO 首次运行使用 `tasks_train.jsonl` 的 80–119 号任务，保持它们不进入离线阶段。

每个在线任务按以下顺序处理：

1. 任务开始时冻结候选快照。快照只含更早的交互，不含当前任务的任何消息；
2. 从 $\pi_{\theta_{\text{old}}}$ 采样 $K = 8$ 个动作，并由 FA 执行。部署规则选出的一个 y_a 交给用户，其余回答只用于组内训练；
3. 读取真实任务结果和用户反应。若用户纠正，允许 FA 重做，直到得到被接受的答案或会话失败；
4. Judge 使用该结果和用户反应给第二步已经生成的回答打分，再按式 (10) 和式 (12) 更新同一个 LoRA；
5. 会话结束后，才把当前记录追加到训练侧历史。新记录只能从下一个任务开始成为候选。

在线新增的是带来源的历史记录，不是模型写出的 hint。这样直接保留用户原话。当前 OOCSSO 中损坏的 hint（例如单字“和”）也不会进入训练。

$\mathcal{D}_{\text{holdout}}$ 和 $\mathcal{X}_{\text{holdout}}$ 在线期间仍不可见。

8 推理

部署时：

1. 对 $\mathcal{D}_{\text{train}}$ 中候选记录计算式 (5)；

2. 按式 (6) 选择索引, 直到 STOP;
3. 由式 (7) 得到 $\pi_\theta(a | x)$;
4. 运行 $y_a = \text{FA.Execute}(a, x)$;
5. 返回 y_a 。

FA 不读取完整 P_u , 除非该版本被单独作为基线。策略输出中没有自然语言控制指令。

9 评测

9.1 必须比较的系统

表 5: 最小对照。

系统	回答的问题
空动作 + FA	不给历史时, 冻结 FA 表现如何?
BM25/语义检索 + FA	普通相似度检索是否已经足够?
π_{base} + FA	未训练的 0.6B 选择器表现如何?
π_θ + FA	下游执行奖励是否学会了更好的历史选择?
全量 $\mathcal{D}_{\text{train}}$ + FA	选择是否优于把所有历史塞给 FA?
原 18 动作 + Compiler + FA	数据驱动动作是否优于手写标签?
旧 4B 直接回答 LoRA	保持冻结 FA 的代价和收益是什么?

9.2 指标

对真实 $\mathcal{X}_{\text{holdout}}$, 在同一个 FA 下比较 y_θ 和 y_{base} :

$$\text{Acc}_c = \frac{1}{N_c} \sum_{x \in \mathcal{X}_{\text{holdout}}^{(c)}} \mathbf{1}[y_\theta \succ y_{\text{base}}], \quad (13)$$

$$\text{Acc}_{\text{macro}} = \frac{1}{|C|} \sum_c \text{Acc}_c, \quad (14)$$

$$\text{Acc}_{\text{micro}} = \frac{1}{N} \sum_c N_c \text{Acc}_c. \quad (15)$$

另外分别报告任务成功率、首次回答符合偏好的比例、所选历史条数、历史 token 数、FA 调用成本和在线新增记录数。个性化与任务成功不能合成一个总分。

10 现有数据能证明什么

当前数据足以完成 student 的端到端小规模验证:

1. 从 student 离线部分建立 8 条候选历史；
2. 用 0-79 号工具任务训练选择器；
3. 从 π_0 开始处理 80-119 号在线任务；
4. 把三条已有在线纠正作为回放测试，检查新增记录路径；
5. 在 30 个 dev/eval 工具任务上检查任务成功。

但它还不能证明正式个性化效果：

- TA 训练历史只有两条，且没有负例；
- teacher 没有训练轨迹；
- 没有按时间冻结的真实用户 $\mathcal{X}_{\text{holdout}}$ ；
- 当前 preview 来自模拟用户，不是真实部署日志。

因此，下一次运行可以报告 feasibility 和任务成功，不能把 `tasks_eval.jsonl` 写成真实用户个性化 holdout。

11 创新边界

历史检索、个性化记忆和策略学习分别已有大量工作。本文不能声称首次检索用户历史。真正需要验证的差异是：

把“选哪段真实历史给冻结黑盒 Agent 看”定义为策略动作，用 Agent 实际执行后的 Judge 分数训练选择器，并让同一动作空间从离线历史自然延伸到在线新增记录。

这项设计的价值不是新名词，而是三个可检查性质：动作来自真实数据、每个动作可追溯、最终任务仍由冻结 FA 完成。只有直接实验超过普通检索和完整历史基线后，才能把它写成方法贡献。